

基于集成学习算法的带钢表面缺陷分类算法研究

宗德祥¹, 蒋 渝², 何永辉¹

(宝山钢铁股份有限公司 1. 中央研究院, 上海 201999; 2. 冷轧厂, 上海 201900)

摘要:介绍了集成学习算法的原理和应用, 针对工业现场特别是带钢表面状态的特殊性, 即具备正常带钢表面, 又含有不影响使用的伪缺陷带钢表面以及含有真实缺陷的带钢表面这一复杂现象, 提出了一种基于集成学习算法进行缺陷过滤并结合多尺度卷积、特征金字塔与视觉注意力机制和传统特征的深度学习网络算法模型。通过对比验证, 集成学习算法具有较高的准确性和鲁棒性, 能够满足工业现场需求。

关键词:集成学习; 目标分类; 带钢表面检测

中图分类号:TP391.41 **文献标志码:**B **文章编号:**1008-0716(2021)03-0016-06

doi:10.3969/j.issn.1008-0716.2021.03.004

Research on classification algorithm of strip surface defects based on ensemble learning algorithm

ZONG Dexiang, JIANG Yu and HE Yonghui

(1. Research Institute, Baoshan Iron & Steel Co., Ltd., Shanghai 201999, China;

2. Cold Rolling Plant, Baoshan Iron & Steel Co., Ltd., Shanghai 201900, China)

Abstract: The principle and application of the ensemble learning algorithm are introduced. Aiming at the particularity of the surface condition of the strip steel in the industrial field, it has both the normal strip surface and the pseudo-defect strip surface that does not affect the use and the strip surface with real defects. A deep learning network algorithm model based on ensemble learning algorithm for defect filtering combined with multi-scale convolution, feature pyramid and visual attention model and traditional features is proposed. Through comparison and verification, the Ensemble learning algorithm has high accuracy and robustness, and can meet the needs of sites.

Key words: ensemble learning; object classification; strip surface inspection

集成学习, 顾名思义, 不是单指某种特定的学习算法, 而是由多种学习算法构建而成的用于解决实际问题的一种理论方法, 目标是获得较高的预测准确率。目前常见的集成学习算法主要有两种^[1]: 基于 Bagging 的算法和基于 Boosting 的算法。其中基于 Bagging 的代表算法有随机森林, 而基于 Boosting 的代表算法则有 Adaboost、GBDT、xgboost 等。

带钢表面质量在线检测系统, 从 20 世纪 50 年代诞生以来, 就开启了缺陷检测识别的征途。伴随着机器学习算法的进步, 这些算法逐步被引入到带钢表面质量在线检测系统中, 使得系统的性能逐步得以提升。然而在实践中, 往往发现常规的算法并不能够满足智慧制造时代的需求。目前常见的基于决策树的算法, 分类准确率通常稳定在 75%~80% 之间, 显然仅能够满足用户最基本的需求。为了解决这一问题, 本文提出了传统算法与深度学习算法相结合的算法, 来实现分类准确性的提升。

宗德祥 高级工程师 1980 年生 2005 年毕业于哈尔滨工业大学 现从事机器视觉研究 电话 13641930631
E-mail zongdexiang@baosteel.com

1 本文算法模型

通过对采集到的带钢图像进行跟踪分析发现,通常情况下,带钢表面真实缺陷发生数同实际采集到的图像数相比,占比在 10% ~ 30% 之间,如图 1 所示,随机抽取 3 个月内生产的 10 卷冷轧钢卷统计出的数据,即意味着存在大量的不含缺陷的图像数据被采集。这些多余的数据将会对后续的缺陷分类产生负面影响。因此,若能有效过滤此类图像数据,将能有效提升系统的性能。

因此,本文提出一种基于集成学习算法进行缺陷过滤并结合多尺度卷积、特征金字塔与视觉注意力机制和传统特征的深度学习网络算法模型,如图 2 所示。该模型算法分为两个主要阶段:第一阶段为虚线框中的部分,称之为缺陷身份过

滤阶段,在该阶段,完成海量的数据筛选工作,从而降低系统的负荷,该阶段也可称之为数据预处理阶段;第二阶段为基于深度学习的目标分类识别阶段,为了提升目标识别准确性,将第一阶段人工设计的特征也作为参数输入到深度神经网络之中,进一步提升系统的精度。




图 1 缺陷所占总图比例统计图

Fig. 1 The proportion of defects

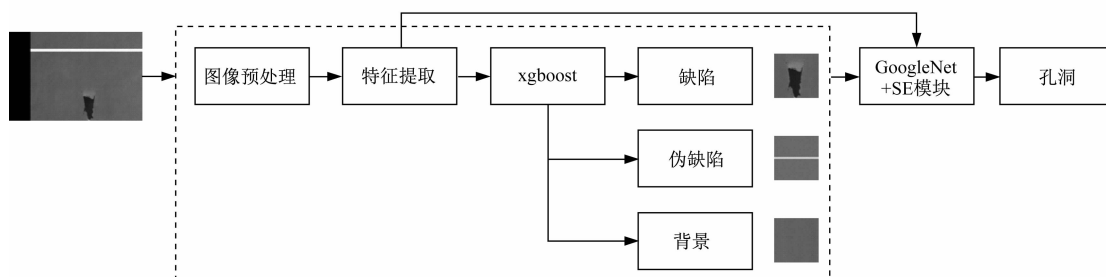


图 2 基于集成学习算法的带钢检测分类模型

Fig. 2 Classification model based on an integrated learning algorithm

1.1 数据预处理

本文数据预处理的目标是为后续目标分类提供合理的数据输入。由于全连接层的存在,一般来说,分类网络需要有固定大小的输入,但是由于缺陷的形态各异、大小不一,如图 3 所示,无法将原始缺陷块直接输入到网络中,因此需要对数据进行预处理,取出固定大小的缺陷块输入到网络中。




图 3 几种典型的缺陷样本

Fig. 3 Several typical defect samples

经过一系列试验对比分析,最终选择一种缺陷块和固定大小背景图融合的方式,由于原始图像较大,选择 256×256 大小的表面干净的钢板背景图,将裁取出的缺陷块和背景融合,具体步骤如下:

(1) 边界提取。

本文采用混合阈值界定法,即采用灰度梯度阈值和灰度阈值联合搜索方法,具体流程如图 4 所示。

在得到待检测图像后首先对其进行了一次 Sobel 算子的 X 方向卷积操作,将之与图像作平面卷积,即可分别得出横向及纵向的亮度差分近似值。从模板可以看出, X 方向模板对于 X 方向上的灰度突变敏感,因而可以很好地检测出竖直边缘,将卷积结果二值化后可以得出比较明显的钢材区域,效果如图 5 所示。

(2) 裁取缺陷块。

根据缺陷顶点坐标和长、宽的数据直接将缺




图 4 边界提取的算法流程

Fig. 4 The algorithmic process for edge extraction



图 5 边界提取效果图

Fig. 5 The result of edge extraction

陷块进行处理,裁取过程中需要注意一下特殊情况,如果缺陷的长度大于 256,则只取中间长度为 256 的缺陷;如果缺陷的高度大于 256,则进行一些缩放和裁剪的操作,保证不会越界。在处理小缺陷块的时候,对缺陷外围适当地向外扩张,以保持检测不完整的情况下能尽量得到更完整的缺陷。得到的缺陷块如图 6 所示。



图 6 图像块

Fig. 6 The image block

(3) 缺陷块与背景融合。

取一张干净的背景图,如图 7。将裁取到的缺陷块以背景钢板图的中心为中心进行融合,采取泊松融合的方式。泊松融合是一种非常强大的图像融合算法,可以把一个前景区域无缝地融合到目标背景图中。它通过计算两个图像交接部分的梯度,然后对两个图像进行适当的调整,使得两个看起来不太融洽的图像看起来是一致的,边界融合效果十分好。泊松融合的效果如图 8。

(4) 图像缩放。

经过泊松融合后的图像大小为 256×256 ,而我们的网络标准输入为 299×299 ,因此需要对图像进行缩放,得到标准的网络输入大小。采用这

种方式可以得到极其干净的缺陷图,比起直接贴图的方式效果更好,除去真实缺陷以外全部都是干净的背景,降低了背景中其他部分对分类造成的影响,同时在进行图像增广的时候,可以通过缺陷块的随机位置放置进行大量的增广。




图 7 背景钢板

Fig. 7 The background of steel image



图 8 泊松融合图

Fig. 8 The result of Poisson fusion

(5) 特征提取。

缺陷图像蕴含丰富的信息,但像素数据太大、太稀疏,直接使用图像上每一个像素来分类要求的计算量是巨大的,同时,通常情况下,单一的像素点没有对应的确定且可解释的意义。因此,图像的内容需要通过一些特征来进行描述。图像的特征包括颜色特征、纹理特征、形状特征、梯度特征等,颜色特征和纹理特征描述了图像区域的表面性质,比如灰度均值、纹理均匀性。形状特征有两类表示方法,一类是轮廓特征,主要针对物体的外边界;另一类是区域特征,主要是描述整个形状区域。梯度特征是基于梯度图生成的,能有效地描述缺陷边缘变化的情况。形状特征包括周长、面积、宽高比等,纹理特征包括纹理对比度、纹理均匀性、纹理熵、纹理二阶矩等,灰度特征包含灰度均值、灰度方差、能量、熵、最大最小灰度值等,梯度特征包含边缘梯度均值、 W 方向梯度均值、 H 方向提取均值、边缘梯度方差等。

(6) xgboost 目标预分类。

xgboost 类似于 GBDT,是一种梯度提升算法的版本。它的思想很简单,由多个弱分类器,经过 Boost 框架,以负梯度为优化目标进行集成学习。它区别于 GBDT 的显著特征是对代价函数进行了

二阶泰勒展开,同时使用了一阶和二阶导数,并且将树的结构作为正则项加到了代价函数中,可以控制模型的复杂度。在本文中,使用二分类的 xgboost 分类器,将上节中提取到的多维传统特征作为输入,为了防止严重缺陷被误丢弃,模型输出结果小于 0.3 判定为伪缺陷,输出结果大于 0.3 则为真实缺陷。

1.2 目标分类识别

结合钢板缺陷分类中存在的缺陷大小不一、长宽比差异大等特点,Inception 模块中的多尺度卷积可以起到很好的特征提取作用,因此,本文采用 GoogleNet - Inception v3 作为基础网络^[2-3]。但是 Inception v3 网络并不能完全解决钢板表面缺陷分类中存在的复杂问题,为了进一步增强通道域的特征表达,在 Inception v3 中引入了基于通道的注意力模块 SENet,其结构如图 9 所示。SENet 的核心思想在于通过网络根基 loss 去学习通道方向的特征权重,增强有效的 feature map,抑制无用的 feature map,以此达到更好的效果。SENet 并不是一个完整的网络结构,而是一个子结构,可以方便地嵌入到任何网络中。虽然插入 SE Block 会增加一些参数和计算量,但是相对于效果的提升是完全可以接受的。




图 9 SENet 模块结构

Fig. 9 The structure of SENet module

为了提高算法的鲁棒性,降低网络的过拟合,还在网络中融合了传统特征。通过图像中计算得到的缺陷形状、灰度、纹理、梯度等传统信息,组合成一个传统特征的嵌入向量,对该向量进行一定的处理后与深度学习模块学习的特征进行融合,融合后的特征再接入到最后的分类层,传统特征的引入能进一步提升网络的分类准确率。

2 模型训练及评估

2.1 数据集

本数据集共包含 24 类缺陷样本,其中 21 类真实缺陷,3 类伪缺陷,总数量 8 876 张样本。数

据集样本分布如图 10 所示。将收集的原始数据以每类 8:2 的比例划分成训练集和测试,由于数据数量较少,难以满足深层的网络对大量数据的需求,所以对原始数据进行部分数据增广操作,在不改变缺陷特征的情况下,使用镜像、翻转、裁剪、平滑去噪、模糊、压缩和拉伸、灰度变化等方式进行增广。通过以上多种数据的数据增广,可以对数据进行数十倍的增广,有效地降低模型的过拟合,增强模型的学习表达能力。

2.2 模型训练

网络训练的流程图如图 11 所示,主要是由正向传播与反向传播交替进行。数据由输入层传入

隐藏层,经过若干层隐藏层处理后传入输出层,由输出层将结果输出的过程被称为正向传播。一次正向传播结束后,需要对比正向传播的输出与正确结果的误差,用这个误差来描述这次网络的状态。反向传播是将误差传递给前一层的过程,基于梯度的误差会一层一层地反向传递到第一层隐藏层,每一层的每个单元会根据误差情况来更新自己的权值。




图 10 样本集

Fig. 10 The set of sample




图 11 模型训练流程

Fig. 11 The model training process

鉴于初期训练网络的样本较少以及训练效率两方面因素,我们采用了迁移学习的思想。初始化低层卷积层参数采用在 ImageNet 上预训练的去掉全连接层的 CNN 模型,因为低层卷积层提取的局部特征主要包括边缘特征、亮度特征等低层语义特征,具有较强的普适性,因而利用预训练好的模型作为模型的初始化参数,可以加快网络的收敛速度。网络的输入图像大小为 299×299 ,网络的训练和评估使用 GTX 1080Ti,训练时 batch

size 设置为 64,测试时为 32,训练 50 个 epochs,初始化学习率设为 10^{-4} ,学习率随 epoch 以一定的规律递减。

2.3 评估标准

对于缺陷分类的评价方法采用常用的图像识别的评价标准。该方法需要已知输入图像缺陷的正确类别,将正确结果与分类器的结果进行对比。将一张缺陷图像输入到训练好的网络中,若类别判定正确,则 $\text{Cor} + 1$,统计整个测试集的所有测试图像的测试结果 (All),记为该算法的识别准确率 Acc ,如公式(1)所示。

$$\text{Acc} = \frac{\text{Cor}}{\text{All}} \times 100\% \quad (1)$$

2.4 试验结果统计

对样本集以 8:2 的比例随机划分训练集和测试集,对测试集进行测试,测试结果如图 12 所示。




图 12 样本分类准确率统计

Fig. 12 Classification accuracy statistics

对算法模型(图 2)进行各模块增删试验,验证本文模型的有效性,如表 1 所示,不同网络结构对目标分类准确率存在较大影响。由试验结果可以看到,在 Inception v3 的基础上加上 SENet 和传统特征能获得最好的效果。

表 1 不同网络结构的分类准确率

Table 1 Classification accuracy of different

network structures			%
Inception v3	SENet	传统特征	分类准确率
✓			95.10
✓	✓		96.95
✓		✓	96.25
✓	✓	✓	97.65

3 结论

(1) 本文所述的基于集成学习算法的带钢表

面缺陷分类算法,将 Googlenet 的多尺度卷积作为骨干网络,用密集成分来近似最优的局部细数结构,引入 SENet 缺陷注意力模块,接入到多尺度卷积网络结构中,它通过压缩—激励—重标定的过程,在通道方向加强有用信息,弱化无用信息,从而达到提高缺陷通道特征注意力的作用。

(2) 在深度学习网络中融入传统特征,如形状、灰度、纹理、梯度和投影等,来加强网络的分类能力和泛化能力。

(3) 结合多尺度卷积、特征金字塔与视觉注意力机制和传统特征的深度学习网络,由于具有较高的鲁棒性和准确性,在工程实践中取得了较好的应用成效,满足用户对质量控制的需求。

参 考 文 献

- [1] TANG Y H, GAO J H, CUI G Z. Ensemble learning with generalization performance measurement and negative correlation [C]//IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence), 2008 :655 – 660.
- [2] 蔡汉明,刘明. 基于 Inception-V3 模型的金属板材表面缺陷检测系统[J]. 轻工机械, 2020, 38(1) :76 – 79.
- [3] 杨炜,周凯霞,刘佳俊,等. 结合迁移学习和 Inception-v3 模型的路面干湿状态识别方法[J]. 中国科技论文, 2019, 14(8) :912 – 916.

(收稿日期:2021 – 01 – 19)